




随机分析

作者：朱占义

时间：August 6, 2026

目录

第 1 章 预备知识	1
1.1 随机过程	1
1.1.1 随机过程	1
1.1.2 分布	2
1.1.3 期望函数、协方差函数和方差函数	5
1.1.4 依赖结构	5
1.2 布朗运动	6
1.2.1 定义	6
1.2.2 有限维分布	7
1.2.3 期望函数和协方差函数	8
1.2.4 路径性质	9
1.3 条件期望	10
1.3.1 对“信息”的认知	10
1.3.2 一般条件期望	12
1.3.3 一般条件期望的特例——离散条件下的条件期望	12
1.3.4 条件期望的计算规则	13
1.3.5 条件期望的投影性质	14
1.3.6 个人体会	14
1.4 鞅	16
1.4.1 定义与性质	16
1.4.2 例子	18
1.4.3 鞅就是公平博弈	21
第 2 章 随机积分	22
2.1 Riemann 积分与 Riemann-Stieltjes 积分	22
2.1.1 普通 Riemann 积分	22
2.1.2 Riemann-Stieltjes 积分	23
2.2 Ito 积分	24
2.2.1 例	24
2.2.2 先对简单过程定义 Ito 积分	26
2.2.3 一般过程 Ito 积分	28
2.3 Ito 引理（微分版本的链式法则）	29
2.3.1 经典链式法则	30
2.3.2 简单 Ito 引理	30

2.3.3 Ito 引理的推广形式	31
2.3.4 分部积分	32
2.3.5 个人体会	33
第 3 章 随机微分方程	34
3.1 Ito 随机微分方程	34
3.1.1 SDE 方程的微分形式	34
3.1.2 SDE 的解	34
3.2 一般线性 SDE	35
3.2.1 具有加性噪声	35
3.2.2 具有乘性噪声的齐次方程	37
3.2.3 最一般情况	37
3.2.4 解的矩的期望函数	38

第 1 章 预备知识

1.1 随机过程

概率	测度论
样本点 ω	集合中的一个元素
样本空间 Ω	集合 Ω
事件 A	集合 Ω 的可测子集
事件族 $\mathcal{F}$	σ -代数
概率 P (定义在事件上)	测度 (定义在集合上)
随机变量 X	可测函数

1.1.1 随机过程

定义 1.1 (随机过程)

随机过程 X 是一个随机变量的集合,

$$(X_t, t \in T) = (X_t(\omega), t \in T, \omega \in \Omega),$$

定义在某个空间 Ω 上 (其中 ω 为样本点, Ω 为样本空间)。



若 T 为一个连续时间区间, 则称 X 为连续时间过程; 若 T 为有限或可数集, 则称 T 为离散时间过程。

一个随机过程是两个变量的函数:

1. 固定时间 t , 它是随机变量:

$$X_t = X_t(\omega), \quad \omega \in \Omega.$$

2. 固定结果 $\omega \in \Omega$, 它是关于时间 t 的函数:

$$X_t = X_t(\omega), \quad t \in T.$$

固定 ω , 再让 t 随时间变化得到的是整条函数。这条函数叫随机过程 X 的一次实现、一条轨迹、一条样本路径。

例题 1.1 客服中心打到电话的数量

假设观察上午 9 点到 10 点一年内打到的电话数。整个随机过程写为

$$X = (X_t)_{t \in T}.$$

这里我们令 T 为时间索引集合，上午 9 点记为 $t = 0$ ，上午 10 点记为 $t = 60$ ，则

$$T = [0, 60].$$

1. ω : 是这一小时内所有电话到达情况的一次完整结果。

例如

$$\omega_0 = (3, 9, 17, 41)$$

表示在第 3, 9, 17, 41 分钟中有电话打进。

2. X_t : 从上午 9 点到 t 时刻为止，已经到达的电话数。

对于固定一个时间 t ， X_t 是一个随机变量； X_t 本质是一套规则。

3. $X_t(\omega)$: 在情形 ω 下，截止时刻 t 已经到达的电话数。

如

$$X_5(\omega_0) = 1, \quad X_{10}(\omega_0) = 2.$$

4. X 和

$$X : T \times \Omega \longrightarrow E$$

并不反映什么实际情况，而是它本身就是一套规则。

随机变量与随机过程的辨析

随机变量 $X(\omega)$ 的实现是一个数字；而随机过程 $X_t(\omega)$ ， $t \in T$ 的实现是 T 上的一个函数。因此随机变量或向量可以理解为具有有限索引集的特殊随机过程。

1.1.2 分布

分布就是给随机对象可能落入的各类集合分配概率。随机对象的“取值”可以是一个数、一个向量，也可以是一整条函数。

1. 狭义概率论中，

$$X : \Omega \longrightarrow \mathbb{R},$$

并定义

$$\mu_X(B) = P(X \in B),$$

其中 $B \subseteq \mathbb{R}$ 是一个合适的可测集。

确定随机向量的分布 $\iff$ 能唯一确定任意可测事件的概率。

2. 随机过程中，

$$X : \Omega \longrightarrow E^T,$$

输入一个“轨迹”，输出一个关于 t 的函数。

相应我们可能要找到 E^T 的合适子集，这很困难的（数学要求高）。

定义 1.2 (随机过程的有限维分布)

随机过程 X 的有限维分布：对所有可能的时间选择

$$t_1, \dots, t_n \in T, \quad n \geq 1,$$

有限向量

$$(X_{t_1}, \dots, X_{t_n}), \quad t_1, \dots, t_n \in T$$

的分布，就是随机过程 X 的有限维分布。

**多元高斯分布**

多元高斯分布（把一维正态分布推广到多个随机变量同时考虑）。

设

$$X = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$$

是一个 n 维随机变量且服从多元高斯分布，则记为

$$X \sim N_n(\mu, \Sigma),$$

其中

$$\mu = \begin{pmatrix} E[X_1] \\ \vdots \\ E[X_n] \end{pmatrix}$$

为均值向量，

$$\Sigma = (\text{cov}(X_i, X_j))_{i,j=1}^n$$

是协方差矩阵。

定义：随机向量

$$X = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$$

是多元高斯，指对任意 $a_1, \dots, a_n$ ，线性组合

$$a_1 X_1 + \dots + a_n X_n$$

都是一维正态随机变量。

密度函数：

若 Σ 是正定矩阵，

$$X \sim N_n(\mu, \Sigma),$$

则其密度函数为

$$f_X(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}.$$

注意： Σ 可以不是正定矩阵。如 $X_1 = X_2$ ，且 X_1 服从标准正态分布，则

$$\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

注意： 并不是 $X_1, \dots, X_n$ 都有正态， $(X_1, \dots, X_n)$ 就是多元高斯。

例题 1.2 正态边际不推出联合正态 如 $Z \sim N(0, 1)$ ，令 $X = Z$ ，并令

$$Y = \begin{cases} Z, & \text{某种情况 } A, \\ -Z, & \text{某种情况 } B. \end{cases}$$

设 S 与 Z 相互独立，且

$$P(S = 1) = P(S = -1) = \frac{1}{2},$$

于是

$$Y = \begin{cases} Z, & S = 1, \\ -Z, & S = -1. \end{cases}$$

对任意集合 A ，

$$P(Y \in A) = \frac{1}{2} P(Z \in A) + \frac{1}{2} P(-Z \in A).$$

由于

$$-Z \stackrel{d}{=} Z,$$

所以

$$P(-Z \in A) = P(Z \in A),$$

从而

$$P(Y \in A) = P(Z \in A),$$

则 $Y \sim N(0, 1)$ 。但 $X + Y$ 不服从正态分布。

注意

在当前教材所采用的标准可测结构下，过程分布与相容的有限维分布一一对应。

例题 1.3 高斯过程 一个随机过程的所有有限维分布都是多元高斯的，则称该过程为高斯过程。

要唯一确定高斯过程的分布，就要知道在任意有限多个时刻上的联合分布是什么，也就是知道

$$(X_{t_1}, \dots, X_{t_n}) \sim N_n \left(\begin{pmatrix} m(t_1) \\ \vdots \\ m(t_n) \end{pmatrix}, (\text{cov}(X_{t_i}, X_{t_j}))_{i,j=1}^n \right).$$

如

$$T = [0, \infty), \quad m(t) = 0, \quad k(s, t) = \min(s, t),$$

能唯一确定一个高斯过程。

1.1.3 期望函数、协方差函数和方差函数

定义 1.3 (期望函数、协方差函数和方差函数)

设 $X = (X_t)_{t \in T}$ 为随机过程。

X 的期望函数为

$$\mu_X(t) = \mu_{X_t} = EX_t, \quad t \in T.$$

X 的协方差函数为

$$C_X(s, t) = \text{cov}(X_t, X_s) = E[(X_t - \mu_X(t))(X_s - \mu_X(s))].$$

X 的方差函数为

$$\sigma_X^2(t) = C_X(t, t) = \text{Var}(X_t), \quad t \in T.$$



1.1.4 依赖结构

仅知道每个时刻 X_t 的边缘分布, 无法描述不同时刻随机变量如何联合变化, 因此还要描述不同时刻之间的关系。

定义 1.4 (平稳过程)

过程 $X = (X_t, t \in T)$, $T \subset \mathbb{R}$, 的有限维分布在索引 t 的平移下保持不变, 即

$$(X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_n+h}),$$

则称随机过程 X 是平稳的。其中

$$t_1, \dots, t_n \in T, \quad n \geq 1,$$

并且

$$t_1 + h, \dots, t_n + h \in T.$$



例题 1.4 平稳高斯过程 由于高斯过程由其期望函数和协方差函数确定, 若

$$\mu_X(t+h) = \mu_X(t), \quad C_X(t, s) = C_X(t+h, s+h),$$

对于所有 $s, t \in T$, 使得 $s+h, t+h \in T$ 成立, 则可推出

$$\mu_X(t) = \mu_X(0), \quad C_X(t, s) = \tilde{C}_X(|t-s|).$$

所以如果一个高斯过程满足

$$\begin{cases} \text{期望为常数,} \\ \text{协方差函数仅依赖于距离 } |t-s|, \end{cases}$$

则这个高斯过程平稳。

定义 1.5 (平稳增量)

设 $X = (X_t, t \in T)$ 为一个随机过程，且 $T \subset \mathbb{R}$ 是一个区间。若对于 $t, s \in T$ ，且 $t+h, s+h \in T$ ，有

$$X_t - X_s \stackrel{d}{=} X_{t+h} - X_{s+h},$$

则称 X 具有平稳增量。



定义 1.6 (独立增量)

设 $X = (X_t, t \in T)$ 为一个随机过程。对于

$$t_1 < \cdots < t_n, \quad n > 1,$$

其中 $t_i \in T$ ，若随机变量

$$X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

相互独立，则称 X 具有独立增量。



例题 1.5 齐次泊松过程 齐次泊松过程具有独立、平稳增量。

1.2 布朗运动

1.2.1 定义

定义 1.7 (布朗运动)

随机过程

$$B = (B_t, t \in [0, \infty))$$

称为布朗运动，如果它满足：

1. 从零出发：

$$B_0 = 0.$$

2. 具有平稳增量和独立增量。

3. 对任意 $t > 0$,

$$B_t \sim N(0, t).$$

4. 具有连续样本路径，即几乎所有样本路径都是连续函数，没有跳跃。



增量的含义

平稳增量是指

$$B_{t+h} - B_{s+h} \stackrel{d}{=} B_t - B_s,$$

只要两边的时间点都有意义。

独立增量是指对任意一组依次排列的时刻

$$0 \leq t_0 < t_1 < \cdots < t_n,$$

随机变量

$$B_{t_1} - B_{t_0}, \quad B_{t_2} - B_{t_1}, \quad \dots, \quad B_{t_n} - B_{t_{n-1}}$$

相互独立。

注 布朗运动在不同时刻的取值一般不独立。独立的是互不重叠时间区间上的增量，而不是 $B_{t_1}, B_{t_2}, \dots, B_{t_n}$ 本身。

1.2.2 有限维分布

命题 1.1 (布朗运动的有限维分布)

布朗运动的有限维分布是多元高斯分布。



证明 任取

$$0 < t_1 < t_2 < \cdots < t_n,$$

并令 $t_0 = 0$ 。定义

$$\Delta B_k = B_{t_k} - B_{t_{k-1}}, \quad k = 1, \dots, n.$$

于是

$$\Delta B_1 = B_{t_1} - B_0 = B_{t_1}.$$

由布朗运动的独立增量可知

$$\Delta B_1, \Delta B_2, \dots, \Delta B_n$$

相互独立；又由平稳增量以及 $B_t \sim N(0, t)$ 可知

$$\Delta B_k \sim N(0, t_k - t_{k-1}).$$

因此

$$\Delta B = \begin{pmatrix} \Delta B_1 \\ \Delta B_2 \\ \vdots \\ \Delta B_n \end{pmatrix}$$

是多元高斯向量。

另一方面,

$$\begin{pmatrix} B_{t_1} \\ B_{t_2} \\ \vdots \\ B_{t_n} \end{pmatrix} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 1 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} \Delta B_1 \\ \Delta B_2 \\ \vdots \\ \Delta B_n \end{pmatrix}.$$

多元高斯向量经过线性变换仍为多元高斯向量, 所以

$$(B_{t_1}, B_{t_2}, \dots, B_{t_n})$$

是多元高斯向量。

1.2.3 期望函数和协方差函数

由定义可得布朗运动的期望函数为

$$\mu_B(t) = EB_t = 0, \quad t \geq 0.$$

下面计算协方差函数。设 $0 \leq s < t$, 则

$$\begin{aligned} C_B(t, s) &= \text{cov}(B_t, B_s) \\ &= E[(B_t - EB_t)(B_s - EB_s)] \\ &= E(B_t B_s) \\ &= E[(B_t - B_s + B_s)B_s] \\ &= E[(B_t - B_s)B_s] + E(B_s^2). \end{aligned}$$

由于 $B_t - B_s$ 与 $B_s = B_s - B_0$ 独立, 且

$$E(B_t - B_s) = 0, \quad EB_s = 0,$$

所以

$$E[(B_t - B_s)B_s] = E(B_t - B_s)EB_s = 0.$$

又因为 $B_s \sim N(0, s)$, 所以

$$E(B_s^2) = \text{Var}(B_s) = s.$$

因此

$$C_B(t, s) = s, \quad 0 \leq s < t.$$

由对称性可得

$$C_B(t, s) = \min(t, s), \quad s, t \geq 0.$$

另一种刻画

布朗运动是一个高斯过程, 其期望函数和协方差函数分别为

$$\mu_B(t) = 0, \quad C_B(t, s) = \min(t, s).$$

反过来，若一个高斯过程具有上述均值函数和协方差函数，并且存在连续样本路径版本，则它就是布朗运动。

1.2.4 路径性质

自相似性

定义 1.8 (H -自相似)

设随机过程

$$X = (X_t, t \in [0, \infty)).$$

若存在 $H > 0$ ，使得对任意 $T > 0$ ，任意 $t_i \geq 0$ ， $i = 1, \dots, n$ ，以及任意 $n \geq 1$ ，有

$$(T^H X_{t_1}, \dots, T^H X_{t_n}) \stackrel{d}{=} (X_{Tt_1}, \dots, X_{Tt_n}),$$

则称 X 是 H -自相似的。



注 自相似性是分布性质，不是路径逐点相等性质。因此上式中的 $\stackrel{d}{=}$ 不能换成 $=$ 。

命题 1.2 (布朗运动的自相似性)

布朗运动是 $\frac{1}{2}$ -自相似的，即对任意 $T > 0$ ，

$$(T^{1/2} B_{t_1}, \dots, T^{1/2} B_{t_n}) \stackrel{d}{=} (B_{Tt_1}, \dots, B_{Tt_n}).$$



证明 两边都是高斯随机向量，所以只需比较它们的期望向量和协方差矩阵。

显然两边的期望向量都为零。对协方差，左边第 i, j 个分量为

$$\text{cov}(T^{1/2} B_{t_i}, T^{1/2} B_{t_j}) = T \min(t_i, t_j).$$

右边第 i, j 个分量为

$$\text{cov}(B_{Tt_i}, B_{Tt_j}) = \min(Tt_i, Tt_j) = T \min(t_i, t_j).$$

两边协方差矩阵相同，因此有限维分布相同。

不可微性和无界变差

路径不规则性

布朗运动虽然具有连续样本路径，但它的样本路径非常不规则。典型结论是：

1. 对几乎所有 ω ，函数 $t \mapsto B_t(\omega)$ 处处不可微。
2. 对任意 $T > 0$ ，对几乎所有 ω ， $t \mapsto B_t(\omega)$ 在 $[0, T]$ 上没有有界变差。

无界变差可以写为

$$\sup_{\tau} \sum_{i=1}^n |B_{t_i}(\omega) - B_{t_{i-1}}(\omega)| = \infty,$$

其中上确界取遍 $[0, T]$ 的所有分割

$$\tau: 0 = t_0 < t_1 < \cdots < t_n = T.$$

直观上，布朗运动路径连续但震荡极其剧烈；把异常样本点去掉后，剩余每条样本路径仍然处处不可微，并且在任意有限时间区间上都没有有界变差。

1.3 条件期望

1.3.1 对“信息”的认知

直观理解（不严谨）：原问题是给定 Y 的值，我们知道所有可能对应的样本点构成的集合。更形象讲，不需要知道 Y 取什么值，而只要知道 Y 对样本空间造成怎样的划分。 $\sigma(Y)$ 就代表随机变量 Y 所包含的全部信息。 Y 的取值对于 $E(X | Y)$ 的定义并不重要，关键在于 Y 的划分方式。条件期望 $E(X | Y)$ 可以理解为由 Ω 的某个子集族 $\sigma(Y)$ 确定的随机变量，

$$E(X | Y) = E(X | \sigma(Y)).$$

定义 1.9 (σ -域)

Ω 上的 σ -域 $\mathcal{F}$ 是 Ω 的一些子集所组成的集合族：

- $\emptyset \in \mathcal{F}$;
- 若 $A \in \mathcal{F}$, 则 $A^c \in \mathcal{F}$;
- 若 $A_1, A_2, \dots \in \mathcal{F}$, 则

$$\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}.$$



定义 1.10 (生成 σ -域)

$\sigma(\mathcal{C})$: 给定 Ω 的一个子集族 $\mathcal{C}$, 包含 $\mathcal{C}$ 的, Ω 上的最小 σ -域.



例: n 维 Borel 集。

$$\Omega = \mathbb{R}^n, \quad \mathcal{C}^{(n)} = \{(a_i, b_i]: -\infty < a_i < b_i < \infty, i = 1, \dots, n\}.$$

n 维 Borel 集的 σ -域为

$$\mathcal{B}^n = \sigma(\mathcal{C}^{(n)}).$$

定义 1.11 (随机向量/随机过程的生成 σ 域)

若 Y 为随机变量, 则

$$\sigma(Y) = \{Y^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\} = \sigma\{Y^{-1}((a, b])\}.$$

$\sigma(Y)$ 是一个集合, 可以理解成样本空间上的事件集合。

若 Y 为随机过程,

$$Y = (Y_t, t \in T, \omega \in \Omega).$$

$$\sigma(Y) = \{\omega : \text{样本路径}(Y_t(\omega), t \in T) \text{ 属于 } C\},$$

其中 C 为适当的 T 上的函数集合。



为什么是 σ 代数这个数学结构

1. 当知道 A 会不会发生, 一定能知道 A^c 会不会发生;
2. 知道 $\emptyset$ 和 Ω 会不会发生;
3. 知道 $A_1, A_2, \dots$ 每一个会不会发生, 就能知道 $A_1 \cup \dots \cup A_n \cup \dots$ 会不会发生。

所以只要是信息结构, 天然就会是一个 σ 代数。

如果我们说某些事件“可判断”, 则这些事件构成的信息结构必须包含在总信息 $\mathcal{F}$ 中, 即

$$\sigma(A_1, A_2, \dots) \subset \mathcal{F}.$$

定义 1.12 (包含信息的关系)

Y, Y_1, Y_2 是 Ω 上的随机变量、向量或随机过程。

1. $\sigma(Y) \subset \mathcal{F}$, Y 的信息包含在 $\mathcal{F}$ 中;
2. $\sigma(Y_1) \subset \sigma(Y_2)$, Y_2 包含的信息比 Y_1 多。

信息就是对未知样本点进行区分的能力。



f 是作用于 Y 的函数, $\sigma(f(Y))$ 由

$$\{\omega : f(Y(\omega)) \in C\}$$

产生。

则对于常数函数 f ,

$$\sigma(f(Y)) \subset \sigma(Y).$$

也就是说 f 作用在 Y 上之后, 不仅没让信息变多, 反而损失了一部分。

定义 1.13 (随机变量 X 关于 $\mathcal{F}$ 可测)

对任意 Borel 集 $B \in \mathcal{B}(\mathbb{R})$,

$$\{\omega : X(\omega) \in B\} \in \mathcal{F}.$$

即

$$\sigma(X) \subset \mathcal{F}.$$

直观上讲, 就是 $\mathcal{F}$ 包含了区分 X 所需要的全部信息。



性质

由于 $\mathcal{F}$ 为 σ 代数, 随机变量 X, Y 均为 $\mathcal{F}$ 可测, 则

$$X + Y, \quad XY$$

同样为 $\mathcal{F}$ 可测。

1.3.2 一般条件期望**定义 1.14 (条件期望)**

随机变量 Z 满足下面条件, 则称它为 σ -域 $\mathcal{F}$ 时 X 的条件期望:

$$Z = E(X | \mathcal{F}).$$

1. $\sigma(Z) \subset \mathcal{F}$;
2. $E(XI_A) = E(ZI_A)$, 对于所有 $A \in \mathcal{F}$.



注: X 与 $E(X | \mathcal{F})$ 不相等。但并不是每个 ω 都相同, 只是在这些集合 A 上期望相同; 同时这也表明条件期望所对应的随机变量有很多种, 只要满足

$$P(Z = \tilde{Z}) = 1$$

即可。

例: 比如

$$Z(\omega) = 5.$$

也可以

$$\tilde{Z}(\omega) = \begin{cases} 100, & \omega = \omega_0, \\ 5, & \omega \neq \omega_0, \end{cases} \quad P(\{\omega_0\}) = 0.$$

1.3.3 一般条件期望的特例——离散条件下的条件期望**定义 1.15 (离散条件下的条件期望)**

若 $P(B) > 0$, 则

$$E(X | B) = \int_{-\infty}^{+\infty} x f_{X|B}(x) dx = \frac{E(XI_B)}{P(B)}.$$

其中

$$I_B(\omega) = \begin{cases} 1, & \omega \in B, \\ 0, & \omega \notin B. \end{cases}$$

可以基于条件期望最本质的定义推导得到。



因此条件期望可以理解为

$$\text{条件期望} = \frac{\text{限制在 } B \text{ 上的平均值}}{B \text{ 发生的概率}}.$$

- 若 X 离散, 则

$$E(X | B) = \sum_{k=1}^{\infty} x_k \frac{P(\{\omega : X(\omega) = x_k\} \cap B)}{P(B)} = \sum_{k=1}^{\infty} x_k P(X = x_k | B).$$

- 若 X 连续, 则

$$E(X | B) = \frac{\int_B x f_X(x) dx}{P(B)} = \frac{\int_{\mathbb{R}} x I_B(x) f_X(x) dx}{P(B)}.$$

注: $E(X | Y)$ 不是 X 的函数, 而是 Y 的函数,

$$E(X | Y) = g(Y).$$

因此条件期望本质其实是随机变量。

条件期望和条件概率的关系

在条件概率的基础上推导得到条件期望, 但条件期望更本质, 能将条件概率看作条件期望的特殊情况。

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

记

$$\mathcal{F}_B = \sigma(\{B\}) = \{\emptyset, \Omega, B, B^c\}.$$

根据离散条件下的条件期望,

$$E(X | \mathcal{F}_B)(\omega) = E(X | B), \quad \omega \in B.$$

对于事件 A , 令 $X = I_A$, 则当 $\omega \in B$ 时,

$$E(I_A | \mathcal{F}_B)(\omega) = E(I_A | B) = \frac{E(I_A I_B)}{P(B)} = \frac{P(A \cap B)}{P(B)}.$$

所以

$$P(A | B) = E(I_A | \mathcal{F}_B)(\omega), \quad \omega \in B.$$

1.3.4 条件期望的计算规则

1. 线性性:

$$E(c_1 X_1 + c_2 X_2 | \mathcal{F}) = c_1 E(X_1 | \mathcal{F}) + c_2 E(X_2 | \mathcal{F}).$$

2. 全期望公式:

$$EX = E[E(X | \mathcal{F})].$$

3. 可测性:

$$\sigma(X) \subset \mathcal{F}, \quad E(X | \mathcal{F}) = X.$$

$$\sigma(X) \subset \sigma(Y), \quad E(X | Y) = X.$$

假如 $Y/\mathcal{F}$ 是能区分抛出的点数, X 是抛出的是奇数还是偶数, 则显然更细分的信息能区分出更粗的。

4.

$$\sigma(X) \subset \mathcal{F},$$

$$E(XG | \mathcal{F}) = X E(G | \mathcal{F}).$$

5. 塔式性质, $\mathcal{F} \subset \mathcal{F}'$:

$$E(X | \mathcal{F}) = E[E(X | \mathcal{F}') | \mathcal{F}].$$

$$E(X | \mathcal{F}) = E[E(X | \mathcal{F}) | \mathcal{F}'].$$

6. $X \perp \mathcal{F}$:

$$E(X | \mathcal{F}) = EX.$$

$$E(h(X, G) | \mathcal{F}) = E_X[h(X, G) | \mathcal{F}].$$

E_X 表示固定其它, 只又对 X 取期望。

1.3.5 条件期望的投影性质

定义 1.16 ($L^2(\mathcal{F})$)

$L^2(\mathcal{F})$ 是由随机变量 Z 构成的集合, 满足:

1. $EZ^2 < \infty$;
2. $\sigma(Z) \subset \mathcal{F}$, 即 Z 为 $\mathcal{F}$ 可测。



条件期望的投影理解

条件期望 $E(X | \mathcal{F})$, 实际就是在已知信息 $\mathcal{F}$ 之后, 对于随机变量 X 的最佳预测, 即

$$E[X - E(X | \mathcal{F})]^2 = \min_{Z \in L^2(\mathcal{F})} E(X - Z)^2.$$

因此我们也可将 $E(X | \mathcal{F})$ 理解为 X 在 $L^2(\mathcal{F})$ 上的投影。

注: 这里的对随机变量的预测, 不是对随机变量 X 取到某个具体值的预测, 也不是对 EX 的预测。一般这些我们都是可以直接求的。这里的预测, 因为 X 为随机变量, 但给落在某个“真真实实”的值, 我们预测就是预测落在。

1.3.6 个人体会

一个特别的疑惑:

比如像 $E(B_5 - B_3 | \mathcal{F}_3)$, 既然时间 3 以前已经发生了, 那不应该是一条确定的轨迹作为条

件吗？比如我们真的知道时间 3 以前的轨迹 $B_u(\omega)$, $0 \leq u \leq 3$, 难道不应该是 $E(B_5 - B_3 \mid \omega)$ 这种形式上不严谨、但可以这样意会的意思吗？

因为条件期望本质上不是针对某一次随机试验结果，而是一个随机变量；并且条件期望不同于一般期望，条件期望自己也是一个随机变量。

所以我们要把这些情况统统一概化。假设我们已经获得了截止某时刻的信息，但不指定是哪一個具体实现，而是在这个信息条件下，对未来随机量作预测。

并且，暂且假设：

一般来说，

$$E(B_5 - B_3 \mid \omega_A)$$

和

$$E(B_5 - B_3 \mid \mathcal{F}_3)$$

未必相等，这个例子是例外。

假设 X 表示未来天气：

$$X = \begin{cases} 1, & \text{未来天气下雨,} \\ 0, & \text{未来天气不下雨.} \end{cases}$$

今天已知天气为多云，则

$$E(X \mid A) = 30\%.$$

今天已知天气为阴雨，则

$$E(X \mid B) = 70\%.$$

而条件期望

$$E(X \mid \mathcal{F})$$

就是一个随机变量。

$\mathcal{F}$ 表示我们掌握的今天的天气信息。

再解释，为什么

$$\sigma(B_3) \subset \mathcal{F}_3.$$

于是

$$E(B_3 \mid \mathcal{F}_3) = B_3.$$

到了时间 3，我们拥有的信息已经足够区分 B_3 所有可能的状态。

例如

$$\sigma(X) \subset \mathcal{F} \implies E(X \mid \mathcal{F}) = X.$$

掷骰子，设

$$\Omega = \{1, 2, 3, 4, 5, 6\},$$

并令

$$X(\omega) = \begin{cases} 1, & \omega = 2, 4, 6, \\ 0, & \omega = 1, 3, 5. \end{cases}$$

$\mathcal{F}$ 表示我们的信息能力可以直接知道骰子点数。若

$$\sigma(X) \subset \mathcal{F},$$

知道具体点数当然能知道奇偶信息，因此

$$E(X | \mathcal{F}) = X.$$

也就是说， $X = 1$ 时，我们因为掌握了这种信息，所以直接就能知道 $X = 1$ 。

若有足够的信息，让 X 不再未知。但作为一个随机试验，毕竟它还没发生，所以结果依然不是确定的，而是随机变量。

个人理解：

条件期望是在已有信息限制下，对未知量做的最佳预测。

这个预测，在某一个具体信息实现下是确定值；但从所有可能信息状态整体看，它仍为一个随机变量。

作为初学者，初次接触随机分析，在理解上尤其是对信息的理解上一定痛苦。它比数分、高代、实变、概率都更加深刻，痛苦能让我们成长。

1.4 鞅

鞅就是对某个信息流满足某种精妙性质的随机过程，本质是具有某种性质的随机过程。

1.4.1 定义与性质

定义 1.17 (滤过)

Ω 上一族 σ -域 $(\mathcal{F}_t, t \geq 0)$ ，满足

$$\mathcal{F}_s \subset \mathcal{F}_t, \quad \text{对所有 } 0 \leq s < t,$$

则称 $(\mathcal{F}_t, t \geq 0)$ 为一个滤过。

直观理解：滤过是一股逐渐增加的信息流。



定义 1.18 (自然滤过)

随机过程 Y 的自然滤过指

$$\mathcal{F}_t = \sigma(Y_s, s \leq t).$$



定义 1.19 (适应于滤过)

若

$$\sigma(Y_t) \subset \mathcal{F}_t, \quad \text{对所有 } t \geq 0,$$

则称随机过程

$$Y = (Y_t, t \geq 0)$$

适应于滤过 $(\mathcal{F}_t, t \geq 0)$ 。



注：显然，随机过程 Y 适应于本身生成的自然滤过。

例： $(B_t, t \geq 0)$ 是布朗运动， $(\mathcal{F}_t, t \geq 0)$ 是相应的自然滤过。

随机过程

$$X_t = f(t, B_t), \quad t > 0,$$

适应于 $(\mathcal{F}_t, t \geq 0)$ ，其中 f 为二元函数。

当然，

$$X_t^{(6)} = \max_{0 \leq s \leq t} B_s$$

这种依赖整个过去的过程也适应。

而

$$X_t^{(7)} = B_{t+1}$$

不适应于布朗运动的自然滤过。

理解

$\mathcal{F}_t$ 包含随机过程从 0 到 t 所有布朗运动的信息，但不包含未来的信息。

定义 1.20 (扩大滤过)

设有两个滤过 $(\mathcal{F}_t)_{t \geq 0}$ 和 $(\mathcal{G}_t)_{t \geq 0}$ 。如果对所有时间 t ，都有

$$\mathcal{F}_t \subset \mathcal{G}_t,$$

则称 $\mathcal{G}_t$ 是 $\mathcal{F}_t$ 的扩大滤过。

也就是说，在每一个时间点都包含更多信息的滤过。

**定义 1.21 (连续时间鞅)**

连续时间随机过程 $X = (X_t, t \geq 0)$ 是关于滤过 $(\mathcal{F}_t, t \geq 0)$ 的连续时间鞅，记作 $(X, (\mathcal{F}_t))$ ，如果满足：

1. 对任意 $t \geq 0$ ， $E|X_t| < \infty$ ；
2. X 适应于 $(\mathcal{F}_t)_{t \geq 0}$ ；
- 3.

$$E(X_t | \mathcal{F}_s) = X_s, \quad 0 \leq s < t.$$

其中 X_s 是 $\mathcal{F}_s$ 对 X_t 的最优预测。



定义 1.22 (离散时间鞅)

离散时间随机过程

$$X = (X_n, n = 0, 1, \dots)$$

是关于滤过 $(\mathcal{F}_n)$ 的离散时间鞅, 如果满足:

1. 对任意 n , $E|X_n| < \infty$;
2. X 适应于 $(\mathcal{F}_n)$;
3. 对任意 $k > 0$,

$$E(X_{n+k} | \mathcal{F}_n) = X_n.$$

等价地, 只需要验证

$$E(X_{n+1} | \mathcal{F}_n) = X_n.$$



鞅的期望函数是常数

对于鞅, 若 $s < t$, 则

$$EX_t = E[E(X_t | \mathcal{F}_s)] = EX_s.$$

因此, 鞅的期望函数是常数。

定义 1.23 (鞅差序列)

若

$$E(Y_{n+1} | \mathcal{F}_n) = 0, \quad Y_{n+1} = X_{n+1} - X_n, \quad n = 0, 1, \dots,$$

则 (Y_n) 称为滤过 $(\mathcal{F}_n)$ 的一个鞅差序列。

这个等价于 (X_n) 是关于滤过 $(\mathcal{F}_n)$ 的鞅。



1.4.2 例子

例 1: 独立随机变量的部分和

(Z_n) 是一列有有限期望的独立随机变量。令

$$R_n = Z_1 + \dots + Z_n.$$

$(\mathcal{F}_n)$ 是关于 R_n 的自然滤过。

证明

1)

$$E|R_n| < E|Z_1| + \dots + E|Z_n| < \infty.$$

2)

$$E(R_{n+1} | \mathcal{F}_n) = E(R_n | \mathcal{F}_n) + E(Z_{n+1}) = R_n.$$

例 2: 收集关于随机变量的信息

Z 是 Ω 上的随机变量, $E|Z| < \infty$, $(\mathcal{F}_t, t \geq 0)$ 是 Ω 上的滤过。令

$$X_t = E(Z | \mathcal{F}_t), \quad t \geq 0.$$

证明

1)

$$E|X_t| = E|E(Z | \mathcal{F}_t)| \leq E(E(|Z| | \mathcal{F}_t)) = E|Z| < \infty.$$

2) 当 $s < t$ 时,

$$E(X_t | \mathcal{F}_s) = E(E(Z | \mathcal{F}_t) | \mathcal{F}_s) = E(Z | \mathcal{F}_s) = X_s.$$

例 3: 布朗运动是鞅

$(B_t, t \geq 0)$ 是布朗运动,

$$\mathcal{F}_t = \sigma(B_s, s \leq t)$$

为其自然滤过。

证明

1)

$$E|B_t| < \sqrt{EB_t^2} = \sqrt{t} < \infty.$$

2) 当 $s < t$ 时,

$$E(B_t | \mathcal{F}_s) = E(B_t - B_s + B_s | \mathcal{F}_s) = E(B_t - B_s) + B_s = B_s.$$

因此 $(B_t, t \geq 0)$ 是关于其自然滤过的鞅。

例 4

$$B_t^3 - 3tB_t.$$

证明

1)

$$E|B_t^3 - 3tB_t| \leq E|B_t^3| + 3tE|B_t| < \infty.$$

2) 当 $s < t$ 时,

$$\begin{aligned}
 E(B_t^3 - 3tB_t \mid \mathcal{F}_s) &= E\left((B_s + (B_t - B_s))^3 - 3t(B_s + B_t - B_s) \mid \mathcal{F}_s\right) \\
 &= E\left(B_s^3 + (B_t - B_s)^3 + 3B_s(B_t - B_s)^2 \right. \\
 &\quad \left. + 3B_s^2(B_t - B_s) - 3tB_s \mid \mathcal{F}_s\right) \\
 &= B_s^3 + 3B_s(t - s) - 3tB_s \\
 &= B_s^3 - 3sB_s.
 \end{aligned}$$

鞅变换

直观理解：用过去的信息决定下注的大小，依然保持公平性。

$$X_n = \sum_{i=1}^n C_i Y_i.$$

Y_i : 第 i 次的收益。

C_i : 第 i 次投入的金额。

若 (Y_n) 为 $(\mathcal{F}_n)$ 的鞅差序列，随机过程

$$C = (C_n, n = 1, 2, \dots)$$

有 $\sigma(C_n) \subset \mathcal{F}_{n-1}$ ，则 X_n 仍为鞅。

1.

$$E|X_n| \leq \sum_{i=1}^n E|C_i Y_i| \leq \sum_{i=1}^n \sqrt{E(C_i^2)E(Y_i^2)} < \infty.$$

2.

$$\begin{aligned}
 E(X_{n+1} \mid \mathcal{F}_n) &= E(X_n + C_{n+1}Y_{n+1} \mid \mathcal{F}_n) \\
 &= X_n + C_{n+1}E(Y_{n+1} \mid \mathcal{F}_n) \\
 &= X_n.
 \end{aligned}$$

布朗鞅变换

取划分

$$0 = t_0 < t_1 < \dots < t_n = t.$$

记

$$\Delta_0 B = 0, \quad \Delta_n B = B_{t_n} - B_{t_{n-1}}.$$

对应前边的鞅变换的符号

$$\Delta_n B \Longleftrightarrow Y_n.$$

$$\sigma(B_{t_0}, \dots, B_{t_n}) \Longleftrightarrow \mathcal{F}_n.$$

$$B_{t_{n-1}} \Longleftrightarrow C_n.$$

并且

$$E(B_{t_{n+1}} | \mathcal{F}_n) = B_{t_n}.$$

1.4.3 鞅就是公平博弈

鞅就是公平博弈

若 $X = (X_t, t \geq 0)$ 是滤过 $\mathcal{F} = (\mathcal{F}_t, t \geq 0)$ 下的鞅，则当 $t > s$ 时，

$$E(X_t | \mathcal{F}_s) = X_s.$$

于是

$$E(X_t - X_s | \mathcal{F}_s) = X_s - X_s = 0.$$

即

$$E(\text{未来收益} | \text{现在信息}) = 0.$$

鞅就是一种“公平赌博”的数学模型。

第 2 章 随机积分

2.1 Riemann 积分与 Riemann-Stieltjes 积分

2.1.1 普通 Riemann 积分

不失一般性，考虑 $[0, 1]$ 上的实值连续函数 f 。

分割

$\mathcal{T}_n$ 为区间 $[0, 1]$ 的一个划分

$$\mathcal{T}_n: \quad 0 = t_0 < t_1 < \cdots < t_{n-1} < t_n = 1.$$

定义

$$\Delta_i = t_i - t_{i-1}.$$

近似求和

σ_n 为 $\mathcal{T}_n$ 下的一种选点方式，满足

$$t_{i-1} < \psi_i \leq t_i.$$

对于给定的划分方式 $\mathcal{T}_n$ 和选点方式 σ_n ，定义 Riemann 和

$$S(\mathcal{T}_n, \sigma_n) = \sum_{i=1}^n f(\psi_i)(t_i - t_{i-1}) = \sum_{i=1}^n f(\psi_i)\Delta_i.$$

取极限

$$\text{mesh}(\mathcal{T}_n) := \max_{i=1, \dots, n} \Delta_i \longrightarrow 0.$$

若

$$S = \lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} S(\mathcal{T}_n, \sigma_n) = \lim_{n \rightarrow \infty} \sum_{i=1}^n f(\psi_i)\Delta_i$$

存在，则 S 称作 f 在 $[0, 1]$ 上的 Riemann 积分，记

$$S = \int_0^1 f(t) dt.$$

例

通过定义法计算

$$\int_0^1 f(t) dt, \quad f(t) = t.$$

分割

$$\mathcal{T}_n: \quad 0 = t_0 < t_1 < \cdots < t_n = 1, \quad t_i = \frac{i}{n}, \quad i = 0, 1, \dots, n.$$

σ_n : 为选定

$$\left(\frac{i-1}{n}, \frac{i}{n} \right]$$

的左端点 $\frac{i-1}{n}$, 其中 $i = 1, \dots, n$ 。

近似求和

$$S(\mathcal{T}_n, \sigma_n) = \frac{1}{n} \left(\frac{0}{n} + \cdots + \frac{n-1}{n} \right) = \frac{(n-1)n}{2n^2} = \frac{n-1}{2n} = \frac{1}{2} - \frac{1}{2n}.$$

取极限

$$\lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} S(\mathcal{T}_n, \sigma_n) = \frac{1}{2}.$$

2.1.2 Riemann-Stieltjes 积分

分割

$$\mathcal{T}_n: \quad 0 = t_0 < t_1 < \cdots < t_{n-1} < t_n = 1.$$

选点 σ_n :

$$t_{i-1} < \psi_i \leq t_i, \quad i = 1, \dots, n.$$

设 f, g 为 $[0, 1]$ 上的实值连续函数,

$$\Delta_i g = g(t_i) - g(t_{i-1}), \quad i = 1, \dots, n.$$

近似求和

$$S_n(\mathcal{T}_n, \sigma_n) = \sum_{i=1}^n f(\psi_i) \Delta_i g = \sum_{i=1}^n f(\psi_i) [g(t_i) - g(t_{i-1})].$$

取极限

若

$$S = \lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} S_n(\mathcal{T}_n, \sigma_n) = \lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} \sum_{i=1}^n f(\psi_i) \Delta_i g$$

存在, 并且 S 与 $\mathcal{T}_n$ 和 σ_n 无关, 则 S 称为 f 关于 g 在 $[0, 1]$ 上的 Riemann-Stieltjes 积分, 记

$$S = \int_0^1 f(t) \, dg(t).$$

Riemann-Stieltjes 积分的一个重要充分条件

满足下列条件，则 Riemann-Stieltjes 积分

$$\int_0^1 f(t) dg(t)$$

存在：

1. f 与 g 不在同一点不连续；
2. $p > 0, q > 0$, f 具有有界 p -变差, g 具有有界 q -变差, 且

$$\frac{1}{p} + \frac{1}{q} > 1.$$

定义 2.1 (有界 p -变差)

若某个 $p > 0$, $[0, 1]$ 上的实值函数 h 满足

$$\sup_T \sum_{i=1}^n |h(t_i) - h(t_{i-1})|^p < \infty,$$

称 h 具有有界 p -变差, 其中 $p = 1$ 时, h 具有有界变差。

**注**

特别地, 令 $B = (B_t, t \geq 0)$ 表示布朗运动。

- $p > 2$: 布朗运动的样本路径在任意固定有限区间具有有界 p -变差;
- $p < 2$: 具有无界 p -变差。

但

$$I(B) = \int_0^1 B_t(\omega) dB_t(\omega)$$

由于布朗运动对于 $p > 2$ 具有有界 p -变差,

$$\frac{1}{p} + \frac{1}{p} > 1$$

并不能被满足。

反应: Riemann-Stieltjes 积分具有很强的局限性。

2.2 Ito 积分

2.2.1 例

例:

$$\int_0^t B_s(\omega) dB_s(\omega)$$

不能作为 Riemann-Stieltjes 积分路径积分。

分割

$$\mathcal{T}_n : \quad 0 = t_0 < t_1 < \cdots < t_n = t.$$

$$\Delta_i = t_i - t_{i-1}, \quad \Delta_i f = f(t_i) - f(t_{i-1}).$$

σ_n 取

$$\psi_i = t_{i-1}.$$

近似求和

$$S_n(\mathcal{T}_n, \sigma_n) = \sum_{i=1}^n B_{t_{i-1}}(B_{t_i} - B_{t_{i-1}}) = \frac{1}{2} \left[B_t^2 - \sum_{i=1}^n (\Delta_i B)^2 \right] = \frac{1}{2} [B_t^2 - Q_n(t)].$$

取极限

$$\text{mesh}(\mathcal{T}_n) \rightarrow 0.$$

$$EQ_n(t) = E \left(\sum_{i=1}^n (\Delta_i B)^2 \right) = \sum_{i=1}^n \Delta_i = t.$$

$$\begin{aligned} \text{Var } Q_n(t) &= \sum_{i=1}^n \text{Var}((\Delta_i B)^2) \\ &= \sum_{i=1}^n \left[E(\Delta_i B)^4 - (E(\Delta_i B)^2)^2 \right] \\ &= \sum_{i=1}^n [E(\Delta_i B)^4 - \Delta_i^2] \\ &= \sum_{i=1}^n [3\Delta_i^2 - \Delta_i^2] \\ &= 2 \sum_{i=1}^n \Delta_i^2. \end{aligned}$$

又

$$2 \sum_{i=1}^n \Delta_i^2 \leq 2 \sum_{i=1}^n \text{mesh}(\mathcal{T}_n) \Delta_i \leq 2t \text{ mesh}(\mathcal{T}_n).$$

因此

$$\lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} \text{Var } Q_n(t) \rightarrow 0.$$

$Q_n(t)$ 均方收敛于 t , 则 $Q_n(t)$ 依概率收敛于 t 。

更换选点方式, 选择 σ'_n :

$$\sigma'_n: \quad \psi_i = t_i.$$

此时求和结果为

$$S_n(\mathcal{T}_n, \sigma'_n) = \frac{1}{2} [B_t^2 + Q_n(t)].$$

$$\lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} S_n(\mathcal{T}_n, \sigma'_n) \neq \lim_{\text{mesh}(\mathcal{T}_n) \rightarrow 0} S_n(\mathcal{T}_n, \sigma_n).$$

因此

$$\int_0^t B_s(\omega) dB_s(\omega)$$

不能作为 Riemann-Stieltjes 积分。

2.2.2 先对简单过程定义 Ito 积分

定义 2.2 (普通简单函数)

把区间切成有限段, 每一段上保持函数值不变。

设

$$f: [0, T] \rightarrow \mathbb{R}.$$

若存在有限划分

$$0 = t_0 < t_1 < \cdots < t_n = T,$$

以及有限个实数

$$a_1, \dots, a_n,$$

使得

$$f(t) = a_i, \quad t_{i-1} < t < t_i,$$

则称 f 为简单函数。



简单函数例子

$$f(t) = \begin{cases} 2, & 0 \leq t < 1, \\ -1, & 1 \leq t < 3, \\ 5, & 3 \leq t \leq 4. \end{cases}$$

定义 2.3 (简单过程)

一个随时间变化, 但只会跳来跳去取有限几个随机变量的随机过程。

存在划分

$$\mathcal{T}_n: \quad 0 = t_0 < t_1 < \cdots < t_{n-1} < t_n = T.$$

以随机变量序列

$$Z_i, \quad i = 1, \dots, n$$

定义

$$C_t = \begin{cases} Z_n, & t = T, \\ Z_i, & t_{i-1} \leq t < t_i, \end{cases}$$

且

$$Z_i \in \mathcal{F}_{t_{i-1}}, \quad EZ_i^2 < \infty.$$



注：首先简单函数就是一种特殊的简单过程。

同时，简单过程取定一个样本点，运行出来的就是简单函数。

简单过程例子

对给定 $[0, T]$ 划分 $\mathcal{T}_n$ ，定义

$$C_t = \begin{cases} B_{t_{n-1}}, & t = T, \\ B_{t_{i-1}}, & t_{i-1} \leq t < t_i. \end{cases}$$

定义 2.4 (简单过程 C 在 $[0, T]$ 上的 Ito 随机积分)

定义

$$\int_0^T C_s dB_s := \sum_{i=1}^n Z_i (B_{t_i} - B_{t_{i-1}}) = \sum_{i=1}^n Z_i \Delta_i B.$$

若未走完全程 T ，而只是到 t ，其中

$$t_{k-1} < t \leq t_k,$$

定义

$$\begin{aligned} \int_0^t C_s dB_s &:= \int_0^T C_s I_{[0,t]}(s) dB_s \\ &= \sum_{i=1}^{k-1} Z_i \Delta_i B + Z_k (B_t - B_{t_{k-1}}). \end{aligned}$$

注：其中

$$\sum_{i=1}^0 Z_i \Delta_i B = 0.$$



Ito 积分就是在左端点计算 C 的路径得到的 Riemann-Stieltjes 积分。

简单过程的 Ito 积分的性质

记

$$I_C(t) = \int_0^t C_s dB_s.$$

1. 对于布朗运动在 $[0, T]$ 上的自然滤过, $(I_C(t), t \in [0, T])$ 是一个鞅, 有

$$E(I_C(t) | \mathcal{F}_s) = I_C(s), \quad s < t.$$

进而能推得

$$E(I_C(t)) = 0.$$

2. 等距性:

$$E \left(\int_0^t C_s dB_s \right)^2 = \int_0^t E C_s^2 ds.$$

积分后的随机波动大小等于原过程波动大小的累积。

注意, 和差不是一回事。

这个性质用来从简单过程推广到一般过程。

3. 线性:

$$\int_0^t (aC_s + bD_s) dB_s = a \int_0^t C_s dB_s + b \int_0^t D_s dB_s.$$

4. 若 $0 < t < T$, 则

$$\int_0^T C_s dB_s = \int_0^t C_s dB_s + \int_t^T C_s dB_s.$$

2.2.3 一般过程 Ito 积分

用简单过程逼近一般过程, 再把积分取极限。

定义 2.5 (可作 Ito 积分的一般过程)

设 $(C_t)_{0 \leq t \leq T}$ 是一个满足

$$E \int_0^T C_t^2 dt < \infty$$

的适应随机过程。

取一系列适应简单过程 $(C_t^{(n)})_{0 \leq t \leq T}$, $n \geq 1$, 使

$$E \int_0^T (C_t^{(n)} - C_t)^2 dt \rightarrow 0,$$

即

$$C^{(n)} \xrightarrow{L^2} C.$$

若

$$\lim_{n \rightarrow \infty} \int_0^T C_t^{(n)} dB_t$$

存在，则定义

$$\int_0^T C_t dB_t := \lim_{n \rightarrow \infty} \int_0^T C_t^{(n)} dB_t.$$



注：其实这就是教材的一种简化的写法。不严谨地说，应该是存在某个随机变量 Δ ，使

$$\lim_{n \rightarrow \infty} E \left| \int_0^T C_t^{(n)} dB_t - \Delta \right|^2 = 0,$$

定义

$$\Delta := \int_0^T C_t dB_t.$$

一般 Ito 积分的性质

设 $C = (C_t, 0 \leq t \leq T)$ 是可积过程。

1. 等距性：

$$E \left(\int_0^t C_s dB_s \right)^2 = \int_0^t E C_s^2 ds.$$

2. 记

$$I_C(t) = \int_0^t C_s dB_s.$$

$(I_C(t))$ 是关于布朗运动自然滤过的鞅，能进而推得

$$E(I_C(t)) = 0.$$

3. 线性：

$$\int_0^t (aC_s + bD_s) dB_s = a \int_0^t C_s dB_s + b \int_0^t D_s dB_s.$$

4. 若 $0 < t < T$ ，则

$$\int_0^T C_s dB_s = \int_0^t C_s dB_s + \int_t^T C_s dB_s.$$

2.3 Ito 引理（微分版本的链式法则）

思考

我认为，从本节到本讲义结尾，其实真正的严格证明不多，但是作为本书用得最多的一部分却都在这里，所以下面的内容其实最好还是要专门记忆一下（虽然框架理解上有直观辅助理解的东西，形式依旧是繁琐的，所以还是记下来比较好）。

先思考一个问题：之前我们有

$$\int_0^t B_s dB_s = \frac{1}{2} B_t^2 - \frac{1}{2} t.$$

而假如 $b(s)$ 为可微函数，由于链式法则，

$$\frac{1}{2} \frac{db(s)^2}{ds} = b(s) \frac{db(s)}{ds},$$

所以

$$\int_0^t b(s) db(s) = \int_0^t b(s) \frac{db(s)}{ds} ds = \frac{1}{2} \int_0^t \frac{db(s)^2}{ds} ds = \frac{1}{2} b(t)^2.$$

为什么会产生这样结果形式的差异呢？根源在于可微性。经典链式法则成立是因为输入函数增量的平方是高阶无穷小，而布朗运动产生的所有可能路径组成的样本空间中，可微路径构成的集合是零概率集合。布朗运动的路径几乎处处不可微，具有非零二次变差，即

$$(dB_t)^2 = dt.$$

所以经典链式法则缺少一个二阶修正项，产生了 $\frac{1}{2}t$ 的修正。

2.3.1 经典链式法则

下面回顾：设 f, g 为可微函数，则经典微分中的链式法则为

$$(f(g(s)))' = f'(g(s))g'(s).$$

积分形式写成

$$f(g(t)) - f(g(0)) = \int_0^t f'(g(s)) dg(s).$$

2.3.2 简单 Ito 引理

设 f 二阶连续可微。积分形式为

$$f(B_t) - f(B_s) = \int_s^t f'(B_u) dB_u + \frac{1}{2} \int_s^t f''(B_u) du, \quad s < t.$$

微分形式为

$$df(B_t) = f'(B_t) dB_t + \frac{1}{2} f''(B_t) dt.$$

注：

$$\frac{df(B_t)}{dB_t} = \left. \frac{df(x)}{dx} \right|_{x=B_t},$$

而

$$\frac{df(B_t)}{dt}$$

一般没有定义。

Ito 引理的证明，其实我们并没有严格给出来。书上的证明只是直观、启发式的，并不严谨，目前仅需以结论为准。

2.3.3 Ito 引理的推广形式

原来的函数 $f(B_t)$ 仅依赖布朗运动；若同时依赖时间 t 和布朗运动 B_t ，则考虑 $f(t, B_t)$ 这样的函数。

推论 I

设 $f(t, x)$ 的二阶偏导连续，则

$$\begin{aligned} f(t, B_t) - f(s, B_s) &= \int_s^t \left[f_1(u, B_u) + \frac{1}{2} f_{22}(u, B_u) \right] du \\ &\quad + \int_s^t f_2(u, B_u) dB_u. \end{aligned}$$

微分形式为

$$df(t, B_t) = \left[f_1(t, B_t) + \frac{1}{2} f_{22}(t, B_t) \right] dt + f_2(t, B_t) dB_t.$$

推论 II

一般 Ito 过程。设

$$X_t = X_0 + \int_0^t A_s^{(1)} ds + \int_0^t A_s^{(2)} dB_s,$$

即

$$dX_t = A_t^{(1)} dt + A_t^{(2)} dB_t,$$

其中 $A_t^{(1)} dt$ 为漂移项。

积分形式为

$$\begin{aligned} f(t, X_t) - f(s, X_s) &= \int_s^t \left[f_1(u, X_u) + A_u^{(1)} f_2(u, X_u) + \frac{1}{2} (A_u^{(2)})^2 f_{22}(u, X_u) \right] du \\ &\quad + \int_s^t A_u^{(2)} f_2(u, X_u) dB_u, \quad s < t. \end{aligned}$$

推论 III

设

$$X_t^{(i)} = X_0^{(i)} + \int_0^t A_s^{(i,1)} ds + \int_0^t A_s^{(i,2)} dB_s, \quad i = 1, 2.$$

考虑

$$f(t, X_t^{(1)}, X_t^{(2)})$$

这样的随机过程, 则

$$\begin{aligned} & f(t, X_t^{(1)}, X_t^{(2)}) - f(s, X_s^{(1)}, X_s^{(2)}) \\ &= \int_s^t f_1(u, X_u^{(1)}, X_u^{(2)}) du + \sum_{i=1}^2 \int_s^t f_{i+1}(u, X_u^{(1)}, X_u^{(2)}) dX_u^{(i)} \\ &+ \frac{1}{2} \sum_{i,j=1}^2 \int_s^t f_{i+1,j+1}(u, X_u^{(1)}, X_u^{(2)}) A_u^{(i,2)} A_u^{(j,2)} du. \end{aligned}$$

2.3.4 分部积分

设

$$\begin{aligned} X_t^{(1)} &= X_0^{(1)} + \int_0^t A_s^{(1,1)} ds + \int_0^t A_s^{(1,2)} dB_s, \\ X_t^{(2)} &= X_0^{(2)} + \int_0^t A_s^{(2,1)} ds + \int_0^t A_s^{(2,2)} dB_s. \end{aligned}$$

则

$$d(X_t^{(1)} X_t^{(2)}) = X_t^{(1)} dX_t^{(2)} + X_t^{(2)} dX_t^{(1)} + A_t^{(1,2)} A_t^{(2,2)} dt.$$

例如计算

$$\int_0^t f(s) dB_s.$$

取

$$\begin{aligned} X_t^{(1)} &= f(t) = f(0) + \int_0^t f'(s) ds + 0, \\ X_t^{(2)} &= B_t = 0 + 0 + \int_0^t 1 dB_s. \end{aligned}$$

则

$$\int_0^t f(s) dB_s = f(t) B_t - f(0) B_0 - \int_0^t f'(s) B_s ds = f(t) B_t - \int_0^t f'(s) B_s ds.$$

上面这个例子, 是我们以后用来计算某种积分的构造工具。

2.3.5 个人体会

在计算过程中，其实有时候 B_t 和 t 看起来像是两个相互独立的自变量。但它们其实是相互耦合的。但依据我们的能力，我们不可能分成两个相互独立的两个自变量。

第3章 随机微分方程

3.1 Ito 随机微分方程

3.1.1 SDE 方程的微分形式

SDE 方程的微分形式为

$$\begin{cases} dX_t = a(t, X_t) dt + b(t, X_t) dB_t, \\ X_0(\omega) = Y(\omega). \end{cases}$$

其积分形式为

$$X_t = X_0 + \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dB_s, \quad 0 \leq t \leq T.$$

3.1.2 SDE 的解

如果存在某个随机过程 $X = (X_t)_{t \geq 0}$, 满足

$$X_t = X_0 + \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dB_s,$$

则称 X_t 为这个 SDE 的解。

因为以后我们研究强解, 所以我们仅给强解下一个定义。

定义 3.1 (强解)

给定概率空间 $(\Omega, \mathcal{F}, P)$ 以及其上一个布朗运动 $B = (B_t)_{0 \leq t \leq T}$, 设

$$\sigma(B_s, s \leq t) \subseteq \mathcal{F}_t.$$

若存在随机过程 $X = (X_t)_{0 \leq t \leq T}$, 满足下列条件:

1. 适应性: (X_t) 适应于 $(\mathcal{F}_t)$;
2. (X_t) 平方可积, 且满足

$$X_t = X_0 + \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dB_s;$$

3. X_t 由 $(X_0, B_s, 0 \leq s \leq t)$ 决定。

(给定初值和过程噪声, X_t 就从头到尾唯一确定。)



强解存在且几乎处处唯一的充分条件

对于 $X_t = X_0 + \int_0^t a(s, X_s) ds + \int_0^t b(s, X_s) dB_s$, 满足

1. $EX_0^2 < \infty$;
2. $a(t, x)$ 和 $b(t, x)$ 关于变量连续;
3. $|a(t, x) - a(t, y)| + |b(t, x) - b(t, y)| \leq K|x - y|$ 。

3.2 一般线性 SDE

考虑

$$X_t = X_0 + \int_0^t [c_1(s)X_s + c_2(s)] ds + \int_0^t [\sigma_1(s)X_s + \sigma_2(s)] dB_s.$$

由满足唯一性的那个充分条件，得到这个方程的强解存在且唯一。

下面介绍三种情况：

$$\begin{cases} \sigma_1(t) = 0, & \text{具有加性噪声;} \\ c_2(t) = \sigma_2(t) = 0, & \text{具有乘性噪声;} \\ \text{最一般情况。} \end{cases}$$

3.2.1 具有加性噪声

此时

方程形式

$$X_t = X_0 + \int_0^t [c_1(s)X_s + c_2(s)] ds + \int_0^t \sigma_2(s) dB_s.$$

由之前的公式

$$X_t = X_0 + \int_0^t A_s^{(1)} ds + \int_0^t A_s^{(2)} dB_s,$$

有

$$\begin{aligned} f(t, X_t) - f(s, X_s) &= \int_s^t \left[f_1 + A_u^{(1)} f_2 + \frac{1}{2} (A_u^{(2)})^2 f_{22} \right] du \\ &\quad + \int_s^t A_u^{(2)} f_2 dB_u. \end{aligned}$$

思路：假设构造一个 $Y_t = f(t, X_t)$ 这样的函数，具体表达式在构造时我们已经知道，即 f_1 、 f_2 、 f_{22} 也知道。假如 $f_1 + A^{(1)} f_2 + \frac{1}{2} (A^{(2)})^2 f_{22}$ 以及 $A^{(2)} f_2$ 的形式中，只含已知的东西，不含 X_t 等，那么这个 $Y_t = f(t, X_t)$ 我们可以求解具体的随机过程表达式，进而反解 X_t 。

此时

$$\begin{cases} A_t^{(1)} = c_1(t)X_t + c_2(t), \\ A_t^{(2)} = \sigma_2(t), \end{cases}$$

从而

$$\begin{cases} f_1 + [c_1(t)X_t + c_2(t)] f_2 + \frac{1}{2} [\sigma_2(t)]^2 f_{22}, \\ \sigma_2(t) f_2. \end{cases}$$

目标是使它们完全已知，并且最好和 X_t 无关。

令 f_2 已知, 并取

$$Y_t = \psi(t)X_t.$$

此时

$$\begin{cases} f_1 = \psi'(t)X_t, \\ f_2 = \psi(t), \end{cases}$$

故

$$\begin{cases} \psi'(t)X_t + [c_1(t)X_t + c_2(t)]\psi(t) + 0, \\ \sigma_2(t)\psi(t). \end{cases}$$

如果

$$\psi'(t)X_t + c_1(t)X_t\psi(t) = 0,$$

则一开始就没有 X_t 。令

$$\psi'(t) = -c_1(t)\psi(t),$$

则

$$\frac{\psi'(t)}{\psi(t)} = -c_1(t), \quad d \ln \psi(t) = d \left(- \int_0^t c_1(s) ds \right),$$

并且

$$\ln \psi(t) = - \int_0^t c_1(s) ds + C.$$

因为满足条件就行, 所以 $C = 0$ 就行, 于是

$$\psi(t) = e^{-\int_0^t c_1(s) ds}.$$

于是

$$Y_t = e^{-\int_0^t c_1(s) ds} X_t = \psi(t)X_t.$$

可以计算得

$$\begin{aligned} Y_t - Y_0 &= Y_t - X_0 \\ &= \int_0^t c_2(u)\psi(u) du + \int_0^t \sigma_2(u)\psi(u) dB_u. \end{aligned}$$

所以

$$Y_t = X_0 + \int_0^t c_2(u)\psi(u) du + \int_0^t \sigma_2(u)\psi(u) dB_u,$$

并得到。为了书写方便, 我们令 $y(t) = \psi(t)^{-1}$ 。

最终结果

$$X_t = y(t) \left[X_0 + \int_0^t c_2(u) y(u)^{-1} du + \int_0^t \sigma_2(u) y(u)^{-1} dB_u \right],$$

其中

$$y(t) = e^{\int_0^t c_1(s) ds}.$$

3.2.2 具有乘性噪声的齐次方程

考虑

方程形式

$$X_t = X_0 + \int_0^t c_1(s) X_s ds + \int_0^t \sigma_1(s) X_s dB_s.$$

思考：令 $X_t = f(t, B_t)$ ，则

$$\begin{aligned} f(t, B_t) - f(s, B_s) &= \int_s^t \left[f_1(u, B_u) + \frac{1}{2} f_{22}(u, B_u) \right] du \\ &\quad + \int_s^t f_2(u, B_u) dB_u. \end{aligned}$$

因此

$$\begin{cases} f_1 + \frac{1}{2} f_{22} = c_1(t) f, \\ f_2 = \sigma_1(t) f. \end{cases}$$

从而

最终结果

$$X_t = X_0 \exp \left\{ \int_0^t \left[c_1(s) - \frac{1}{2} \sigma_1^2(s) \right] ds + \int_0^t \sigma_1(s) dB_s \right\}.$$

3.2.3 最一般情况

求解

方程形式

$$X_t = X_0 + \int_0^t [c_1(s) X_s + c_2(s)] ds + \int_0^t [\sigma_1(s) X_s + \sigma_2(s)] dB_s.$$

令

$$dY_t = c_1(t) Y_t dt + \sigma_1(t) Y_t dB_t, \quad Z_t = Y_t^{-1} X_t.$$

则可得

$$dZ_t = [c_2(t) - \sigma_1(t)\sigma_2(t)]Y_t^{-1} dt + \sigma_2(t)Y_t^{-1} dB_t.$$

所以

最终结果

$$X_t = Y_t \left[X_0 + \int_0^t [c_2(s) - \sigma_1(s)\sigma_2(s)] Y_s^{-1} ds + \int_0^t \sigma_2(s) Y_s^{-1} dB_s \right],$$

其中

$$Y_t = Y_0 \exp \left\{ \int_0^t \left[c_1(s) - \frac{1}{2} \sigma_1^2(s) \right] ds + \int_0^t \sigma_1(s) dB_s \right\}.$$

3.2.4 解的矩的期望函数

仍考虑

$$X_t = X_0 + \int_0^t [c_1(s)X_s + c_2(s)] ds + \int_0^t [\sigma_1(s)X_s + \sigma_2(s)] dB_s.$$

由于随机积分期望为 0, 令

$$u_X(t) = EX_t,$$

则

$$u_X(t) = u_X(0) + \int_0^t [c_1(s)u_X(s) + c_2(s)] ds,$$

即

$$u'_X(t) = c_1(t)u_X(t) + c_2(t).$$

令

$$q_X(t) = EX_t^2.$$

取 $f(t, x) = x^2$, 则 $f(t, x)$ 可以利用第二章 Ito 积分的推广公式:

$$\begin{aligned} X_t^2 &= X_0^2 + \int_0^t \left\{ 2X_s [c_1(s)X_s + c_2(s)] + [\sigma_1(s)X_s + \sigma_2(s)]^2 \right\} ds \\ &\quad + \int_0^t 2X_s [\sigma_1(s)X_s + \sigma_2(s)] dB_s. \end{aligned}$$

因此

$$\begin{aligned} q_X(t) &= q_X(0) + \int_0^t \left\{ [2c_1(s) + \sigma_1^2(s)] q_X(s) \right. \\ &\quad \left. + 2[c_2(s) + \sigma_1(s)\sigma_2(s)] u_X(s) + \sigma_2^2(s) \right\} ds, \end{aligned}$$

即

$$q'_X(t) = [2c_1(t) + \sigma_1^2(t)] q_X(t) + 2[c_2(t) + \sigma_1(t)\sigma_2(t)] u_X(t) + \sigma_2^2(t).$$